

Active Deep Learning for Activity Recognition with Context Aware Annotator Selection

H M Sajjad Hossain, Nirmalya Roy

出典: KDD 2019

概要

機械学習モデルは訓練やテストに使う *grand truth* なデータの信頼性によって制限される。問題のドメインにかかわらず、この *grand truth* なアノテーションは、かなりの労力が必要。複数のアノテータによる能動学習の登場によって、もっとも情報量が多いインスタンスを選択することである程度はこの負担を軽減することができる。しかしながら異なる専門知識をもつ複数のアノテータは、受け取ったラベルデータの品質とアノテータの入手可能性に関して新しい問題が出てくる。日常生活動作 (ADLs) の変化に対する *grand truth* な情報の量が限られているため、ウェアラブル端末を用いた活動認識モデルは、実世界で使うにはまだまだ堅牢ではない。本論文では、我々はまずはじめに、ジョイントロス関数で最適化する、能動学習の *deep* モデルを提案する。次に、アノテータの専門性と空間的コンテキストに関するアノテータ間の異質性の関係を抽出した新しいアノテータ選択モデルを提案する。我々のモデルは *model-free* な深層強化学習を使う。実世界で行った実験では、我々の能動深層モデルは少ないラベルインスタンスで収束し、少ないイテレーションで 8% の精度向上を達成した。選択した理由

- アノテーションに関することばかりだったため。
- ちゃんと実世界で実験を行っていたから。

1 INTRODUCTION

- ウェアラブル端末の発展により、高度なセンシング機能がついて ADLs についてデータをたくさんキャプチャできるようになった。
- ADLs の識別モデルは従来は大量の教師付きデータを用いた学習を行っている。
- 異なる制約に関してある行動に関して、異なる種類の情報を捉える必要がある。
- たとえば、“料理”の行動にしても、食文化や、生活環境、食材とかで行動が変わってしまう。
- 訓練するときにこんなノイズや様々な種類がモデルのパラメータの収束に関わってくる。
- この問題を解決するために、多様な環境から得られた大量の教師付きデータを使うのが普通。
- ディープモデルは複雑なパターンを入力として受け取り、いい感じのパラメータを学習してくれる性質があるからよく使われている。
- けど、学習するのに大量のデータになっちゃう。
- 異なる状況から教師付きデータを集めるのは大変。
- 活動認識では、研究者がカメラやセンサーでデータを取り、アノテーション作業を専門家が行う。
- 大量のデータを限られた専門家がアノテーションするのは大変。クラウドソーシングを用いても、ドメインの知識が不足したり、品質が保証できない
- 本論文では、我々はジョイントロス関数で最適化するディープモデルでの能動学習のブレンドを提案する。
- こうすることで、ラベルのないデータも訓練に使うことができる。
- 我々のモデルは、外れ値も取り扱えて、同じような行動の多様なデータ分布にも適用することができる。
- またアノテータ選択モデルとしては、深層強化学習のアルゴリズムを利用する。
- 貢献は以下の通り。
 - ディープモデルを取り入れた能動学習による活動認識モデルを提案する。これらは少ない教師データで収束する。
 - 教師なしデータを含めたデータのディープモデルを最適化するのに使う、ジョイントロス関数を提案する。
 - 深層強化学習を用いたアノテータ選択モデルを提案する。actor-critic ネットワークを用いて学習していく。
 - スマホアプリを開発して、それをつかってデータを集める。

2 RELATED WORK

3 OVERALL

- 我々のモデルは 2 つの大きな構成要素がある。(能動深層モデルとアノテータ選択モデル)
- 概要は図 1

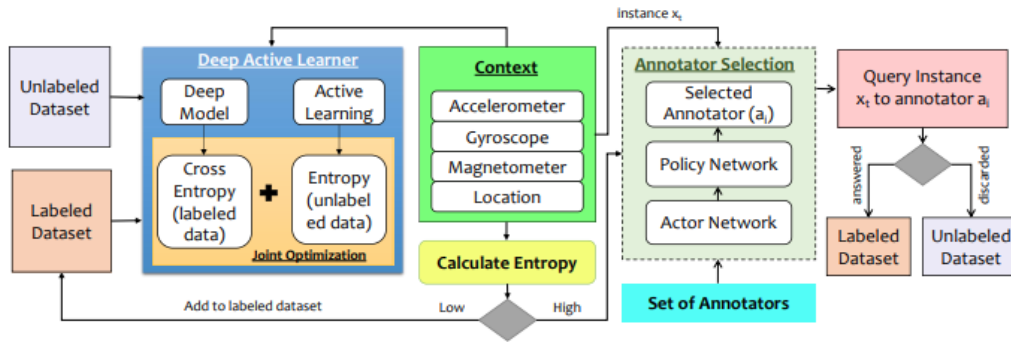


Figure 1: A High level architecture of our proposed model. The left side of the figure illustrates our active learning enabled deep model and in the right side of the figure our annotator selection pipeline is shown.

図 1: 概要図

- 私たちのモデルでは、データのエントロピーを計算することで、不確かさの度合いを計算する。
- どの情報が情報量が多いか適切に求めるのは必要。
- 能動学習にディープモデルを適用するためには、各々の目的関数の最適化をくつつける必要がある。
- ニューラルネットワークの交差エントロピーとエントロピー関数を組み合わせた joint loss 関数を定義する。
- モデルの訓練には教師つきとなしの両方を使う。
- 教師付きはクロスエントロピー、教師なしはエントロピーの計算で使う。
- データはユーザ自身が持っているスマートフォンから得る。スマホのセンサから、いろんな情報を得ることができる。
- 得られた情報の中から最大のエントロピーをもつ情報を選び出す。この得られた情報に対してアノテータにアノテーションしてもらう。
- どのあてのテータにアノテーションしてもらうかは、我々の提案する深層強化学習によって決める。
- アノテータ選択モデルは actor/critic のネットワークで構成されている。
- actor ネットワークの目的は、現在のユーザのコンテキストから最適なアノテータを予測する。
- critic ネットワークは、最適な方策に到達しようと、アノテータから得られる報酬を計算する。
- なんでこれを選んだかという、連続状態空間のためである。
- アノテータにクエリを投げて、回答してもらう。回答がなかったら、また Unlabeled Dataset に戻す

4 DEFINITIONS & PRELIMINARIES

5 METHODOLOGY

6 EXPERIMENTAL EVALUATION

実験では以下の事柄について、注目していきたい。

- 深層学習と能動学習をくつつけた joint loss 関数はどんくらい効果的?
- 行動の分類と行動の学習どちらも他のユーザでも適用できる?
- 訓練の時教師なしデータ使うのはよかったの?
- データの中で情報量が多いものを求めるのは、効果あったの?外れ値を処理するときの有用性はあった?
- 1 日でどれくらいクエリ作れるの?どれくらい大変?
- それぞれのアノテータのパフォーマンスはどう?
- アノテータからのフィードバックは有用?

6.1 System Implementation

- アプリのスクショは図 2

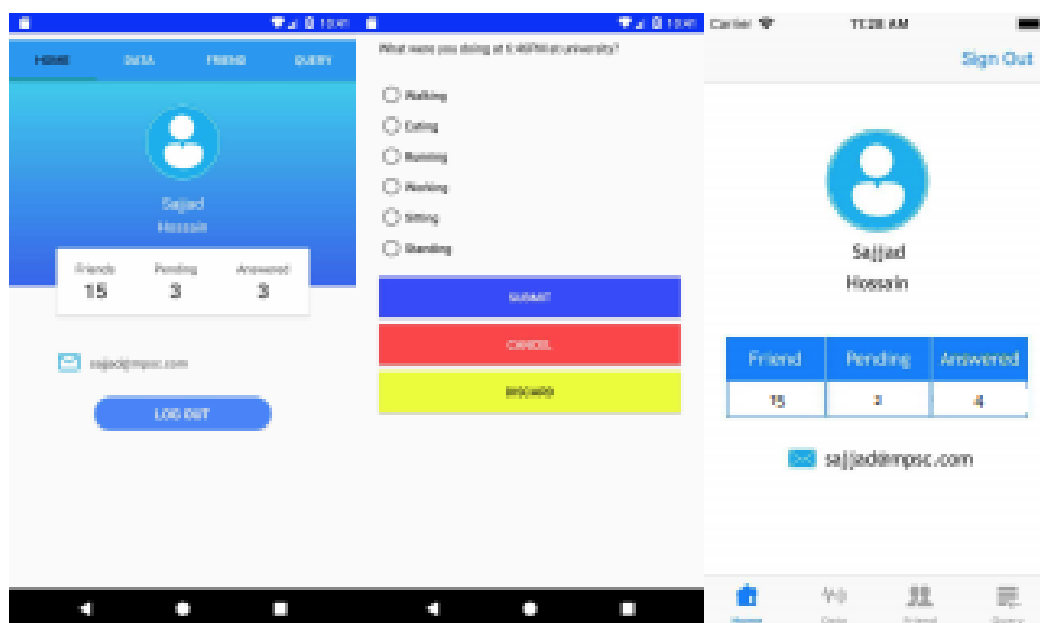


Figure 3: SocialAnnotator application interface.

図 2: アプリのスクショ

6.2 Data Collection & Preprocessing

- 20 人 (男性 14 人, 女性 6 人) から一ヶ月かけてデータを集める.
- 分類したい行動は {walking,eating,running,working,sitting,standing}
- 10 秒おきにスマホからデータを収集.
- モデルを訓練するのに 20 人から 10 人のデータをつかう.

6.3 NetWork Architecture

- 深層能動学習は CNN でできている.
- アノテータ選択モデルの actor/critic ネットワークは, 図 3

6.4 Classifier Performance

- 全体での accuracy は 92.05%
- 各行動での混同行列は図 4
- 'eating' がもっとも悪い精度→'sitting' と状況があまり変わらないから
- いろんな結果図 5
- joint loss 関数の効果を見るために, レイヤーごとの重みの分布を図 6 で示す.
- 重みが大きくなればなるほど, そのレイヤーは入力データの小さなノイズにも敏感になる.
- joint loss での最適化のおかげで, ノイズのあるデータの影響を軽減することができる.
- 教師付き, 教師なしデータを使った時は Accuracy が 83.26%




Figure 5: Architecture of actor-critic network.

図 3: actor/critic ネットワーク

Table 1: Confusion Matrix

	Walking	Eating	Running	Sitting	Standing
Walking	98.19%	0%	1.12%	0.19%	0.50%
Eating	2%	79%	0%	16.10%	3.9%
Running	0.72%	0%	99.17%	0%	0.11
Sitting	1.01%	11%	0.38%	87.56%	0.05%
Standing	0.02%	2.38%	0.21%	1.03%	96.36%

図 4: 混同行列




Figure 4: (a) shows precision, recall and F1-score of our classifier for different activities. (b) the trend of loss function during training and testing. (c) illustrates average reward received with respect to number of epochs while training. (d) shows the progression of normalized reward with respect to number of posed queries.

図 5: いろんな結果




Figure 8: Weight distribution in log scale of different layers using cross-entropy loss.

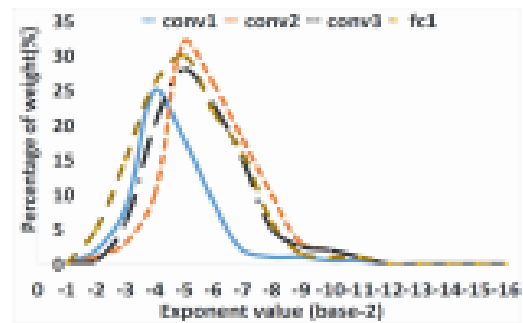


Figure 9: Weight distribution in log scale of different layers using our joint loss function.

図 6: レイヤーごとの重み分布

6.5 Annotator Selection

- アノテータ選択モデルの有用性を Deep Q-Network と比較する.
- 二つの手法どちらも報酬が noisy だけど, DQN より報酬高い.
- DQN よりも早く収束して, 報酬もいい.
- 各個人の報酬の分布を図 7 で示す. User12,14,19,6 の報酬高い. 報酬高い人にクエリを割り当てると効率がいい.



Figure 6: The plot illustrates the reward distribution of 20 users during our experiment.




Figure 7: The figure illustrates the labeling time distribution of 20 users.

図 7: 個人ごとの報酬

6.6 Impact of Active Learning

- モデルの検証したときの accuracy 図 8

Table 2: Comparison of our algorithm with other existing approaches with varying number of queries.

AR System	Number of Queries				
	0	100	200	300	400
Francisco [19]	81.2	84.14	87.87	88.57	89.47
Ming Zeng et al. [35]	80.39	82.47	86.33	87.59	89.25
Mohammad et al. [3]	81.01	83.17	84.11	87.89	88.32
Our model	83.26	85.65	88.39	90.48	91.64

図 8: モデルの検証

7 CONCLUSION AND FUTURE WORK

- 現在の作業では, システムがユーザーに提示できるクエリの数による予算を考慮していない

- 将来的にはアノテーター選択モデルのクエリ予算やアノテーターの可用性などより多くの制約を調査したい

8 感想

式を完全に追っていないので，終えたら終えたい．能動学種と強化学習まだちょっとわからないな．